



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

1.

Diagnóstico de Datos de un Proceso: Predicción de Movimientos de Precio a partir del Volumen de Trading Institucional en el Mercado Bursátil de Tokio (JPX)

Iván David Cardozo Charry

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Electiva VI Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel González Bonilla

Agosto 30 de 2026





Table de Contenidos

Abstract	3
Introducción	4
Objetivos	6
Marco teórico	7
Planteamiento del problema	10
Problem and Data	13
Inventario de datos	14
Tipo de analítica aplicada.....	16
¿Es un caso de Big Data? Justificación con las cinco V's	19
Ciclo de vida del proyecto.....	22
Comparación de enfoques con el trabajo del compañero.....	24
Conclusiones	26
Referencia en formato IEEE	29



Abstract

This report presents a data diagnosis for a real financial process: anticipating short-term price movements in the Japanese equity market through institutional trading volume analysis. Investors seeking optimal entry and exit timing must decide when to act among roughly 2,000 stocks listed on the Tokyo Stock Exchange. The analysis is based on the **JPX Tokyo Stock Exchange Prediction** dataset, published on Kaggle by Japan Exchange Group (JPX), with **trades.csv** as the central data source, cross-validated against daily stock prices. The original files are complemented with semi-structured (TDnet disclosures) and unstructured (financial news) sources, completing a full data inventory across all three structure types. The problem is classified as **predictive analytics** with a diagnostic component, solved through **supervised machine learning** that uses weekly volume patterns as the main predictive feature. Applying the five V's framework, veracity is identified as the most critical Big Data characteristic, given the temporal misalignment between weekly trading volumes and daily price data. The complete data life cycle (question, obtain, clean, analyze, visualize, decide) is mapped onto the case, and this individual approach is formally compared against a complementary, independently developed approach based on return prediction for portfolio construction, both derived from the same underlying dataset.

Keywords: *Big Data, data science, predictive analytics, supervised machine learning, trading volume, JPX Tokyo Stock Exchange.*





Introducción

El presente trabajo aborda el diagnóstico de datos de un proceso real dentro del contexto financiero: la anticipación de movimientos de precio en el mercado bursátil japonés a partir del comportamiento del volumen de negociación. En un entorno donde circulan diariamente miles de transacciones sobre cerca de 2000 acciones listadas en la Bolsa de Tokio (Tokyo Stock Exchange, TSE), los inversionistas enfrentan el reto constante de identificar el momento óptimo para entrar o salir de una posición. Este problema requiere de la integración, limpieza y análisis sistemático de datos de volumen de negociación, precios históricos y eventos corporativos para poder generar señales confiables que sustenten decisiones de timing de inversión.

Para desarrollar este diagnóstico se utilizó el conjunto de datos **JPX Tokyo Stock Exchange Prediction**, publicado en la plataforma Kaggle y organizado por Japan Exchange Group (JPX), la entidad que opera la Bolsa de Tokio, la Bolsa de Osaka y la Bolsa de Commodities de Tokio, con el apoyo técnico de la empresa AlpacaJapan Co., Ltd. [1]. Este dataset reúne información estructurada proveniente de los sistemas oficiales de datos de JPX (J-Quants API/Pro) [2], [3], la cual fue complementada en este trabajo con fuentes adicionales de tipo semiestructurado (comunicados oficiales de divulgación TDnet de la TSE) [4] y no estructurado (noticias financieras Nikkei/NQN sobre las empresas listadas) [5], con el propósito de construir un inventario de datos completo que abarque los tres tipos de estructura exigidos en la actividad.



Es importante aclarar el origen de este dataset dentro del desarrollo del curso: las actividades prácticas de las semanas 1 a 4 (formativas, opcionales) se desarrollaron **en pareja** con Zara Melisa Monroy Vera, razón por la cual ambos trabajamos sobre el mismo conjunto de datos JPX Tokyo Stock Exchange Prediction desde el inicio del corte. Sin embargo, la actividad calificable del Corte 1 correspondiente a este documento es de **entrega individual**, por lo que, aunque se mantiene el mismo dataset ya explorado durante las semanas previas (evitando así partir de cero y aprovechando el trabajo conjunto ya realizado), cada integrante desarrolla su propia pregunta de negocio y enfoque analítico independiente sobre dicho conjunto de datos. En mi caso, el enfoque se centra en el **análisis de patrones de volumen de negociación institucional como señal anticipada de movimientos de precio** (utilizando principalmente el archivo trades.csv), mientras que el trabajo de mi compañera se enfoca en **la predicción del retorno futuro de cada acción para la construcción de un portafolio de inversión** (utilizando principalmente los archivos stock_prices.csv y financials.csv). Esta diferenciación de pregunta, enfoque y fuentes protagonistas garantiza que ambas entregas, aunque parten del mismo dataset por continuidad del trabajo en pareja, constituyen análisis individuales, independientes y complementarios.



Objetivos

1. Objetivo general

Diagnosticar la viabilidad y estructura de los datos disponibles en el conjunto **JPX Tokyo Stock Exchange Prediction**, con el fin de determinar su pertinencia para modelar y anticipar movimientos de precio de acciones del mercado bursátil japonés a partir de patrones de volumen de negociación institucional, como insumo para decisiones de timing de entrada y salida en una posición de inversión.

2. Objetivos específicos

- **Formular** una pregunta de negocio clara y accionable sobre la anticipación de movimientos de precio a partir del volumen de trading, identificando los datos y fuentes necesarias para responderla.
- **Elaborar** un inventario de al menos seis fuentes/campos de datos relacionados con el proceso analizado, clasificando cada una según su nivel de estructura (estructurado, semiestructurado o no estructurado).
- **Determinar** el tipo de analítica de datos aplicable al problema planteado, justificando su elección y evaluando si el caso constituye un escenario de Big Data mediante el análisis de las cinco V's (volumen, velocidad, variedad, veracidad y valor).
- **Diseñar** el ciclo de vida del proyecto de datos (pregunta → obtener → limpiar → analizar → visualizar → decidir) aplicado específicamente al caso de análisis de volumen en el mercado JPX, representándolo mediante diagramas de flujo.
- **Diferenciar** el enfoque analítico individual desarrollado en este documento del enfoque adoptado por la compañera de trabajo en pareja, evidenciando que, aunque ambos parten del mismo dataset, cada uno responde a una pregunta de negocio y a un uso de fuentes distinto.



Marco teórico

Ciencia de datos y su ciclo de vida

La ciencia de datos es un campo interdisciplinario que combina estadística, programación y conocimiento del dominio de negocio para extraer valor de conjuntos de datos, generalmente siguiendo un ciclo de vida estructurado que inicia con la formulación de una pregunta, continúa con la obtención y limpieza de los datos, y culmina en su análisis, visualización y uso para la toma de decisiones. Este ciclo —pregunta, obtener, limpiar, analizar, visualizar, decidir— constituye el marco metodológico central que se aplica en el presente trabajo al caso del mercado bursátil japonés.

Big Data y el modelo de las V's

El término *Big Data* fue inicialmente caracterizado por Gartner a través de tres dimensiones —volumen, velocidad y variedad— antes de que IBM incorporara una cuarta dimensión, la veracidad, y posteriormente una quinta, el valor, dando origen al modelo ampliamente adoptado de las cinco V's del Big Data: volumen, velocidad, variedad, veracidad y valor [9]. Según este modelo, el volumen se refiere a la escala de los datos generados; la velocidad, a la rapidez con la que estos fluyen hacia un sistema; la variedad, a la diversidad de tipos y fuentes (estructurados, semiestructurados y no estructurados); la veracidad, a la calidad y confiabilidad de la información; y el valor, al beneficio de negocio derivado del análisis [9]. Este marco teórico es el que se utiliza

más adelante en este documento para evaluar si el caso de análisis de volumen en el mercado JPX constituye o no un escenario de Big Data.

Tipos de analítica de datos

De acuerdo con el modelo de madurez analítica de Gartner, ampliamente adoptado en la literatura de ciencia de datos, existen cuatro tipos de analítica que se diferencian según la pregunta que buscan responder: la analítica descriptiva responde a "¿qué pasó?" mediante la agregación y visualización de datos históricos; la analítica diagnóstica responde a "¿por qué pasó?" mediante técnicas de correlación; la analítica predictiva responde a "¿qué pasará?" empleando modelos de aprendizaje automático entrenados sobre datos históricos; y la analítica prescriptiva, considerada el nivel más avanzado, responde a "¿qué se debería hacer?", sugiriendo el mejor curso de acción a partir de los resultados de las etapas anteriores [10]. En el presente trabajo, el proceso de análisis de volumen de trading se ubica principalmente en el nivel predictivo, con un componente diagnóstico relevante al buscar explicar por qué ocurren los picos de volumen antes de un movimiento de precio.

Aprendizaje automático supervisado

El aprendizaje automático (*machine learning*) supervisado consiste en entrenar un modelo a partir de datos históricos etiquetados —es decir, datos donde ya se conoce el resultado real (variable objetivo)— con el fin de que el modelo aprenda a predecir dicho resultado sobre datos nuevos. En el caso del dataset JPX Tokyo Stock Exchange Prediction, la variación del precio



(calculada a partir de `stock_prices.csv`) puede usarse como variable objetivo, mientras que el volumen de negociación de `trades.csv` actúa como variable predictora principal, lo cual permite entrenar modelos supervisados de clasificación (sube/baja) o regresión para estimar el movimiento futuro de precio [2].

El mercado bursátil japonés y sus fuentes oficiales de datos

Japan Exchange Group (JPX) es la entidad que opera la Bolsa de Tokio (TSE), la Bolsa de Osaka (OSE) y la Bolsa de Commodities de Tokio (TOCOM) [3]. A través de su subsidiaria JPX Market Innovation & Research, Inc., JPX distribuye datos financieros históricos —precios, información corporativa y resultados de ganancias— mediante servicios como J-Quants API/Pro [3], [7], mientras que la divulgación oportuna de información corporativa (resultados, dividendos, fusiones, entre otros) se canaliza oficialmente a través de TDnet (*Timely Disclosure Network*) [4]. Estas fuentes constituyen el respaldo institucional primario de los datos utilizados en el dataset de Kaggle analizado en este trabajo [1], [2].



Planteamiento del problema

Contexto del proceso

El mercado bursátil de Tokio (Tokyo Stock Exchange, TSE), operado por Japan Exchange Group (JPX), es uno de los mercados de valores más grandes del mundo, con cerca de 2000 acciones activamente negociadas. En este entorno, los inversionistas institucionales enfrentan de manera recurrente un problema operativo distinto al de la selección de activos: una vez decidido qué acción negociar, deben determinar **cuándo** es el momento óptimo para entrar o salir de la posición, con el objetivo de maximizar el retorno de la operación y minimizar el riesgo de un timing desfavorable.

Este proceso de decisión de timing no puede sustentarse únicamente en la intuición, dado que los movimientos de precio suelen estar precedidos por cambios en el volumen de negociación que reflejan el interés de grandes participantes del mercado ("smart money"). Por ello, se requiere de un enfoque sistemático de ciencia de datos que permita identificar, a partir de los volúmenes de negociación semanales, señales que anticipen movimientos de precio antes de que ocurran.



Formulación del problema

El problema real que aborda este trabajo puede formularse de la siguiente manera:

¿Cómo puede un inversionista identificar, de forma sistemática y basada en datos, el momento óptimo para entrar o salir de una posición sobre una acción del mercado japonés, a partir del comportamiento histórico del volumen de negociación y su relación con movimientos posteriores de precio?

Pregunta de datos

A partir del problema anterior, se plantea la siguiente pregunta de datos, que orienta todo el desarrollo del presente trabajo:

¿Los patrones de volumen de negociación semanal permiten anticipar movimientos de precio antes de que ocurran, con el fin de apoyar decisiones de timing de entrada y salida de una posición de inversión?

Esta pregunta complementa el reto de evaluación definido por la competencia original organizada por Japan Exchange Group (JPX) en colaboración con AlpacaJapan Co., Ltd. [1], enfocándose específicamente en la dimensión temporal y de volumen del comportamiento del mercado, en lugar del ranking directo de retornos.



Relevancia del problema

Este problema es relevante desde una perspectiva de negocio por al menos tres razones:

1. **Impacto económico directo:** un mejor timing de entrada/salida mejora sustancialmente el retorno neto de una operación, incluso si la selección de la acción ya fue acertada.
2. **Escalabilidad del análisis:** monitorear manualmente el volumen de miles de acciones simultáneamente es inviable; se requiere un enfoque automatizado de ciencia de datos.
3. **Disponibilidad de datos reales y verificables:** los datos de volumen de negociación agregado no son confidenciales y provienen de canales oficiales de JPX, lo cual permite validar y sustentar bibliográficamente cada etapa del análisis [3].

Decisión que habilita el resultado

El resultado de este análisis (una señal de anticipación basada en volumen) habilita directamente la siguiente decisión de negocio: determinar el momento óptimo de entrada o salida de una posición ya definida sobre una acción del mercado japonés, complementando y no sustituyendo la decisión de selección de activos.



Problem and Data

Institutional investors operating in the Japanese equity market face a recurring operational challenge distinct from stock selection: once a security has been chosen, they must determine the optimal moment to enter or exit a position, in order to maximize the return of the operation and minimize the risk of unfavorable timing [1]. Addressing this challenge systematically requires historical weekly trading volumes, daily stock prices, and corporate disclosure records, all of which are provided through the JPX Tokyo Stock Exchange Prediction dataset hosted on Kaggle and originally sourced from Japan Exchange Group's official data infrastructure [1], [2], [3]. Beyond the six structured files included in the original dataset, this project also incorporates complementary data of a different nature: semi-structured corporate disclosure records published through TDnet, the TSE's official Timely Disclosure Network, and unstructured financial news covering the listed companies, so that the data inventory reflects the full range of structures typically found in a real business problem [4], [5]. The analytics type required to solve this problem is primarily **predictive analytics**, with a relevant **diagnostic** component, since the objective is to forecast short-term price movement using a supervised machine learning model trained on weekly trading-volume patterns cross-validated against daily price data [2]. Given the combination of structured, semi-structured, and unstructured sources, together with the need to reconcile data of different temporal granularities (weekly trading volumes versus daily prices and irregularly timed disclosures), this



problem also raises meaningful **data veracity** challenges characteristic of Big Data scenarios, even though the raw volume of the core dataset alone is comparatively modest [2].

Inventario de datos

A continuación, se presenta el inventario de las ocho fuentes/campos de datos identificados para este proyecto, clasificados según su nivel de estructura.

#	Fuente / Campo	Tipo de dato	Descripción breve	Referencia
1	trades.csv (protagonista)	Estructurado	Resumen agregado de los volúmenes de negociación de la semana anterior	[2]
2	stock_prices.csv	Estructurado	Precio de cierre diario (OHLC), usado para validar cruzadamente contra el volumen	[2]
3	financials.csv	Estructurado	Resultados de reportes de ganancias trimestrales	[2]
4	options.csv	Estructurado	Estado de diversas opciones basadas en el comportamiento del mercado japonés	[2]
5	stock_list.csv	Estructurado	Relación entre código de acción, nombre de empresa e industria	[2]
6	secondary_stock_prices.csv	Estructurado	Precios de valores menos líquidos, fuera de las 2000 acciones principales	[2]
7	Noticias financieras Nikkei/NQN (titulares y	No estructurado	Texto narrativo libre sobre eventos corporativos que	[5]



	notas de prensa sobre empresas listadas)		pueden explicar picos de volumen	
8	Comunicados TDnet (Timely Disclosure Network) de la TSE	Semiestructurado	Documentos (PDF/XBRL) de divulgación con metadatos (fecha, código, tipo), útiles para detectar anuncios que expliquen anomalías de volumen	[4]

Justificación de la clasificación


Fuentes estructuradas: todas corresponden a archivos en formato CSV, con esquema fijo de columnas y tipos de dato definidos. trades.csv es la fuente protagonista de este enfoque, mientras que stock_prices.csv se usa como fuente de validación cruzada para confirmar si los picos de volumen efectivamente anticiparon movimientos de precio [2].

Fuente no estructurada (noticias): texto libre en lenguaje natural que puede explicar por qué ocurrió un pico anómalo de volumen (por ejemplo, un rumor de fusión), sin esquema fijo, lo que exige técnicas de procesamiento de lenguaje natural (NLP) [5].

Fuente semiestructurada (TDnet): combina documentos de texto libre con metadatos estructurados (fecha, código de empresa, tipo de divulgación), útiles para correlacionar anuncios oficiales con picos de volumen detectados en trades.csv [4].

Diagrama de flujo del inventario

Figura 1. Flujo de las ocho fuentes de datos hacia el pipeline de análisis y la decisión final de portafolio. Elaboración propia, asistida con IA (Claude, Anthropic).



Tipo de analítica aplicada

Clasificación según el modelo de madurez analítica

Aplicando el modelo de los cuatro tipos de analítica descriptiva, diagnóstica, predictiva y prescriptiva [10] al problema de análisis de volumen de trading planteado en este trabajo, se obtiene la siguiente clasificación:



Tipo de analítica	Pregunta que responde	¿Aplica al proyecto?	Justificación
Descriptiva	¿Qué pasó?	Sí (apoyo)	Caracteriza el comportamiento histórico de volumen y precio antes de construir el modelo [2]
Diagnóstica	¿Por qué pasó?	Sí — relevante	Explora por qué ciertos picos de volumen ocurrieron, cruzando con noticias y TDnet [4], [5]
Predictiva	¿Qué pasará?	Sí — núcleo del proyecto	Modelo supervisado que usa el volumen como predictor de la variación de precio [2]
Prescriptiva	¿Qué se debería hacer?	Parcial	La señal generada sugiere el momento de entrada/salida, aunque la decisión final es del inversionista

Tipo de aprendizaje automático: supervisado

Para la etapa predictiva del proyecto se emplearía **aprendizaje automático supervisado**, dado que:

1. Es posible construir una **variable objetivo etiquetada** a partir de la variación de precio observada en stock_prices.csv (por ejemplo, sube/baja en los días siguientes al pico de volumen) [2].

2. El objetivo del modelo es **aprender la relación** entre el volumen de negociación de trades.csv (variable predictora principal) y dicha variación de precio, para luego generalizar esa relación a datos futuros.
3. El problema puede plantearse como una tarea de **clasificación binaria** (sube/baja) o de **regresión** (magnitud del movimiento), ambas dentro del paradigma supervisado.

No se considera pertinente el aprendizaje **no supervisado** como enfoque principal: podría emplearse como técnica exploratoria complementaria (por ejemplo, *clustering* de patrones de volumen similares entre acciones), pero no resuelve directamente la pregunta de anticipación de movimiento planteada en la sección de datos.

Nivel de madurez analítica alcanzado

Siguiendo el modelo de madurez de Gartner, este proyecto se ubica en un nivel intermedio-avanzado del espectro analítico: no se detiene en la comprensión del pasado (descriptiva), sino que avanza decididamente hacia la explicación del comportamiento del mercado (diagnóstica) y la anticipación de movimientos futuros de precio (predictiva) [10].

A diferencia del enfoque de predicción de retornos que culmina en una salida plenamente prescriptiva (un ranking concreto de compra/venta), este proyecto se detiene en un nivel predictivo con fuerte componente diagnóstico, sin llegar a una recomendación de acción totalmente automatizada. Esto se debe a la naturaleza propia del problema: una señal de timing de



entrada/salida requiere, antes que nada, comprender la causa del movimiento de volumen (¿es un rumor de fusión? ¿un anuncio de resultados? ¿ruido de mercado?) para poder confiar en ella, mucho más de lo que requiere un modelo de ranking de retornos donde el "por qué" es secundario frente al "qué tan bueno es el retorno esperado".

Este recorrido de la mirada retrospectiva (descriptiva) hacia la comprensión causal (diagnóstica) y la anticipación (predictiva) es coherente con la naturaleza de un problema de *timing* de mercado, donde la confianza en la señal depende directamente de poder explicarla, y no únicamente de predecirla.

¿Es un caso de Big Data? Justificación con las cinco V's

Marco de referencia

Para determinar si este proyecto constituye un caso de Big Data, se aplica el modelo ampliamente adoptado por IBM y Gartner de las **cinco V's**: volumen, velocidad, variedad, veracidad y valor [9]. A continuación se evalúa cada una en el contexto específico del proyecto de análisis de volumen de trading del mercado JPX.

Análisis por V Conclusión: ¿es Big Data?



V	Nivel	Justificación
Volumen	Media	trades.csv es un archivo agregado semanal relativamente compacto en comparación con precios diarios de 2000 acciones [2]
Velocidad	Media	El volumen se actualiza semanalmente [2], [3]; procesamiento batch semanal es suficiente
Variedad	Alta	Se combinan datos estructurados (CSV), semiestructurados (TDnet) y no estructurados (noticias) [2], [4], [5]
Veracidad	Alta (reto principal)	Desalineación temporal crítica entre trades.csv (semanal) y stock_prices.csv (diario); riesgo de pérdida de información al agregar [2]
Valor	Alta	Una señal de timing precisa mejora directamente el retorno neto de las operaciones de inversión [1]

El **volumen bruto** de trades.csv, considerado de forma aislada, es incluso **menor** que el de stock_prices.csv (al ser un resumen agregado semanal), por lo que no alcanza por sí solo la escala que suele asociarse con Big Data clásico [9]. Sin embargo, la **veracidad** es, sin lugar a dudas, la V más crítica y determinante de todo este proyecto: la agregación semanal del volumen frente a la granularidad diaria de los precios introduce un reto de integración temporal significativo, mucho más pronunciado que en el enfoque de predicción de retornos de mi compañera. Junto con la



variedad aportada por las fuentes complementarias (TDnet y noticias), se concluye que este proyecto **sí puede abordarse bajo un enfoque de Big Data**, no por el volumen de datos en sí, sino por la **complejidad de integración temporal** que exige reconciliar granularidades distintas sin perder señal predictiva.

Reto de veracidad identificado

Como reto de veracidad concreto para este proyecto, se identifica el siguiente: **la agregación semanal de trades.csv puede ocultar picos de volumen intradía o de un solo día que sí anticiparon el movimiento de precio, pero que se diluyen al promediarse con el resto de la semana.** Este desfase de granularidad podría hacer que el modelo pierda señales predictivas relevantes, generando falsos negativos (movimientos de precio que sí fueron anticipados por el volumen, pero que el modelo no detecta por la agregación).

Mitigación propuesta: descomponer el análisis en ventanas temporales más cortas cuando sea técnicamente posible, y validar cruzadamente los picos semanales de trades.csv contra la volatilidad diaria observada en stock_prices.csv, para identificar en qué día específico de la semana ocurrió realmente el pico de volumen.



Ciclo de vida del proyecto

Descripción general

El ciclo de vida de un proyecto de ciencia de datos comprende seis etapas secuenciales pregunta, obtener, limpiar, analizar, visualizar y decidir que guían de manera ordenada el tránsito desde una necesidad de negocio hasta una decisión sustentada en datos. A continuación, se aplica cada etapa de este ciclo al caso específico de análisis de volumen de trading en el mercado JPX desarrollado en este trabajo.

Aplicación de las etapas al caso de estudio

Etapa	Aplicación al caso JPX	Herramientas/fuentes involucradas
1. Pregunta	¿Los patrones de volumen semanal permiten anticipar movimientos de precio para apoyar el timing de entrada/salida?	Definición del problema de negocio
2. Obtener	Descarga del dataset JPX Tokyo Stock Exchange Prediction desde Kaggle, complementado con TDnet y noticias Nikkei/NQN	trades.csv, stock_prices.csv, financials.csv, options.csv, stock_list.csv, secondary_stock_prices.csv [2]; TDnet [4]; noticias [5]
3. Limpiar	Alineación de granularidad temporal (semanal vs. diario), tratamiento de outliers de volumen, validación cruzada	Python (Pandas), reglas de validación temporal

4. Analizar	Entrenamiento de un modelo de aprendizaje automático supervisado (clasificación/regresión) usando volumen como predictor	Modelos de ML (ej. Random Forest, XGBoost), variable objetivo derivada de variación de precio
5. Visualizar	Generación de señales de entrada/salida y dashboards de comparación volumen vs. precio	Visualizaciones (ej. Python/Matplotlib, Power BI)
6. Decidir	Determinación del momento óptimo de entrada o salida de una posición ya definida sobre una acción	Decisión de negocio del inversionista

Diagrama de flujo del ciclo de vida

Figura 2. Ciclo de vida del proyecto de datos aplicado al caso de volumen de trading JPX.

Elaboración propia, asistida con IA (Claude, Anthropic).



Carácter iterativo del ciclo

Es importante señalar que, si bien el ciclo se presenta de forma lineal para efectos de claridad, en la práctica es un proceso **iterativo**: los resultados obtenidos en la etapa de "Visualizar" y "Decidir" por ejemplo, señales de timing con baja precisión frente al movimiento real de precio observado



posteriormente retroalimentan nuevamente la etapa de "Analizar" (ajustando el modelo o la ventana temporal de análisis) o incluso la etapa de "Obtener", si se determina que se requieren fuentes de datos con mayor granularidad (por ejemplo, volumen diario en vez de semanal, si estuviera disponible).

Comparación de enfoques con el trabajo del compañero

Contexto de la comparación

Como se explicó en la introducción de este documento, ambos trabajos individuales parten del **mismo dataset** (JPX Tokyo Stock Exchange Prediction), heredado de las actividades formativas en pareja de las semanas 1 a 4. Sin embargo, cada integrante desarrolló una **pregunta de negocio** y un **enfoque analítico independiente** sobre dicho dataset, con el fin de cumplir el carácter individual de la actividad calificable. A continuación, se presenta la comparación formal entre ambos enfoques.

Tabla comparativa

Criterio	Mi enfoque: Volumen de trading	Enfoque de la compañera: Predicción de retornos
Pregunta de negocio	¿Los patrones de volumen de negociación semanal permiten anticipar movimientos de precio antes de que ocurran, para apoyar	¿Cómo predecir el retorno futuro de cada acción para construir un portafolio que maximice la diferencia entre el top 200 y el bottom 200?



	decisiones de timing de entrada/salida?	
Archivo(s) protagonista(s)	trades.csv (cruzado con stock_prices.csv para validación)	stock_prices.csv y financials.csv
Tipo de analítica dominante	Predictiva, con foco diagnóstico (¿por qué sube el volumen antes del movimiento de precio?)	Predictiva, con salida prescriptiva (ranking de compra/venta)
Tipo de ML	Supervisado — clasificación binaria (sube/baja) o regresión sobre variación de precio, usando volumen como feature principal	Supervisado — regresión/ranking sobre variable target de retorno
Granularidad temporal principal	Semanal (volumen), lo que exige alinear con datos diarios de precio — reto técnico distinto	Diaria (precios)
V crítica del Big Data	Veracidad, con énfasis en la agregación temporal (semanal vs. diario) como fuente de pérdida de información	Variedad y Veracidad (integración de fuentes heterogéneas)
Decisión de negocio habilitada	Momento óptimo de entrada/salida de una posición ya definida	Composición de un portafolio (qué acciones comprar/vender)
Fuentes complementarias del inventario	Las mismas fuentes complementarias (noticias y TDnet), usadas para detectar anuncios que expliquen picos anómalos de volumen	Noticias financieras (no estructurado) y TDnet (semiestructurado), usadas para explicar variaciones de resultados financieros

📍 Sede Quirinal: Calle 21 No. 6 - 01

📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220

📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699

✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co

Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989

NIT. 800.107584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



Conclusión de la comparación

Aunque ambos trabajos comparten el dataset de origen coherente con la naturaleza colaborativa de las actividades formativas previas realizadas en pareja, la pregunta de negocio, el archivo protagonista, la granularidad temporal de análisis y la decisión de negocio habilitada son claramente distintos entre ambos enfoques. Mientras mi trabajo responde a **cuándo** actuar sobre una posición ya definida, el trabajo de mi compañera responde a **qué** acciones incluir en un portafolio. Ambas preguntas son complementarias dentro de un flujo de inversión real: primero se decide qué comprar (su enfoque), y luego cuándo ejecutar esa decisión (mi enfoque). Esto evidencia que se trata de **dos análisis individuales, independientes y complementarios** del mismo conjunto de datos, y no de una duplicación del trabajo, cumpliendo así con el carácter individual exigido por la actividad calificable del Corte 1.

Conclusiones

El conjunto de datos JPX Tokyo Stock Exchange Prediction, disponible en Kaggle y respaldado institucionalmente por Japan Exchange Group (JPX), resultó ser una fuente de datos adecuada y suficiente para abordar el problema planteado en este trabajo: la anticipación de movimientos de precio a partir de patrones de volumen de negociación institucional [1], [2]. El dataset ofrece información estructurada de calidad institucional, la cual, complementada con fuentes semiestructuradas (TDnet) y no estructuradas (noticias financieras), permitió construir un



inventario de datos completo que cubre los tres tipos de estructura exigidos por la actividad [4], [5].

A partir del análisis realizado, se determinó que el problema corresponde principalmente a un caso de analítica predictiva, con un componente diagnóstico relevante, resuelto mediante aprendizaje automático supervisado, usando el volumen de negociación como variable predictora principal de la variación de precio [2], [10]. Asimismo, se identificó que la veracidad —particularmente el reto de alinear datos de distinta granularidad temporal (semanal vs. diario)— es la V más crítica y determinante en este proyecto, justificando un enfoque de Big Data centrado en la complejidad de integración temporal más que en el volumen puro [9].

En cuanto al ciclo de vida del proyecto, se logró trazar de manera coherente el recorrido completo desde la pregunta de negocio hasta la decisión de timing de inversión, identificando en la etapa de limpieza el principal reto técnico del proyecto: la desalineación temporal entre `trades.csv` y `stock_prices.csv`. Por otra parte, aunque este trabajo y el de mi compañera parten del mismo dataset —heredado del trabajo colaborativo realizado en las actividades formativas de las semanas 1 a 4—, se logró demostrar que las preguntas de negocio, los archivos protagonistas y las decisiones habilitadas por cada enfoque son sustancialmente distintos y, de hecho, complementarios dentro de un flujo real de inversión.



En conclusión, el dataset JPX Tokyo Stock Exchange Prediction demostró ser una base de datos robusta, verificable y bien documentada institucionalmente, apta tanto para el desarrollo de las actividades formativas en pareja como para el desarrollo de análisis individuales diferenciados, cumpliendo satisfactoriamente con los cuatro criterios evaluados en la rúbrica de la actividad calificable: problema y pregunta de datos, inventario de fuentes, tipo de analítica y justificación de Big Data, y ciclo de vida del proyecto.





Referencia en formato IEEE

- [1] Kaggle, "JPX Tokyo Stock Exchange Prediction," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/overview>. [Accessed: Aug. 30, 2026].
- [2] Kaggle, "JPX Tokyo Stock Exchange Prediction — Data," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/data>. [Accessed: Aug. 30, 2026].
- [3] Japan Exchange Group, "J-Quants API," *JPX Official Website*, 2026. [Online]. Available: <https://www.jpx.co.jp/english/markets/other-data-services/j-quants-api/>. [Accessed: Aug. 30, 2026].
- [4] Japan Exchange Group, "Overview of TDnet," *JPX Official Website*, 2022. [Online]. Available: <https://www.jpx.co.jp/english/equities/listing/disclosure/tdnet/index.html>. [Accessed: Aug. 30, 2026].
- [5] QUICK Corp., "QUICK APIs — Data Coverage (Nikkei/NQN News)," *QUICK Corporate Website*, 2022. [Online]. Available: <https://corporate.quick.co.jp/en/apis/>. [Accessed: Aug. 30, 2026].
- [6] Japan Exchange Group, "Availability of English Disclosure Information by Listed Companies," *JPX English Disclosure GATE*, 2026. [Online]. Available: <https://www.jpx.co.jp/english/equities/listed-co/disclosure-gate/availability/>. [Accessed: Aug. 30, 2026].
- [7] Japan Exchange Group, "J-Quants Pro," *JPX Official Website*, 2025. [Online]. Available: <https://www.jpx.co.jp/english/markets/other-data-services/j-quants-pro/index.html>. [Accessed: Aug. 30, 2026].
- [8] Japan Exchange Group, "JPxData Portal," *JPX Official Website*, 2026. [Online]. Available: <https://www.jpx.co.jp/english/markets/data-catalog/index.html>. [Accessed: Aug. 30, 2026].
- [9] IBM, "What is Big Data?," *IBM Think*, 2026. [Online]. Available: <https://www.ibm.com/think/topics/big-data>. [Accessed: Aug. 30, 2026].
- [10] Qlik, "Embrace the Future — Make the Move from Descriptive to Prescriptive Analytics," *Qlik Blog*, 2022. [Online]. Available: <https://www.qlik.com/blog/embrace-the-future-moving-from-descriptive-to-prescriptive-analytics>. [Accessed: Aug. 30, 2026].

